



University of Ljubljana
Faculty of *Electrical Engineering*

Optimizacija v telekomunikacijah

Situacijsko zavedanje pametnega doma

Poročilo projekta

Avtor: Leon Ciglar

Mentor: prof. dr. Andrej Košir

Študijski program: 1. letnik, BMA Elektrotehnika, IKT

Ljubljana, maj 2024

Kazalo vsebine

1	Uvod.....	3
2	Pristop k reševanju problema in ocena uspešnosti.....	4
2.1	Metode.....	4
2.2	Merjenje uspešnosti rešitve	5
3	Eksperimentalni rezultati.....	6
3.1	Testni podatki:	6
3.2	Ovrednotenje rezultata.....	8
4	Izzivi.....	10
5	Zaključek in možne nadgradnje	11
6	Literatura	12

Kazalo slik

Slika 1: Poraba Microwave v kW za prvih 1000 vzorcev	6
Slika 2: ON/OFF vrednosti za Microwave	7
Slika 3: Dendrogram.....	7
Slika 4: Rezultat - Prisotnost osebe v domu	8
Slika 5: Izmerjene vrednosti porabnikov v kW skozi čas	8
Slika 6: Binarne vrednosti porabnikov	9
Slika 7: Prisotnost osebe in binarne vrednosti porabnikov skozi čas	9

Povzetek

V sklopu projekta smo razvili algoritem, ki na osnovi podatkov o moči porabnikov v pametnem domu določa prisotnost izbrane situacije, kot je na primer situacija: prisotnost osebe doma. Uporabili smo metode nenadzorovanega učenja, kot je hierarhično grozdenje, za analizo vzorcev uporabe različnih naprav. Končni rezultat je časovna funkcija, ki prikazuje prisotnost osebe skozi čas.

1 Uvod

V zadnjih letih je tehnologija pametnih domov doživela izjemen napredek, kar je privedlo do večje avtomatizacije in optimizacije vsakodnevnih opravil. Pametni domovi vključujejo različne naprave in sisteme, ki omogočajo boljše upravljanje energije, avtomatizacijo ter udobje. Ena izmed ključnih komponent pametnega doma je situacijsko zavedanje, ki omogoča, da se sistem prilagaja trenutnim razmeram in potrebam uporabnikov.

Situacijsko zavedanje poleg prednosti za uporabnika, kot so avtomatizacija, boljša uporabniška izkušnja, enostavnejše upravljanje z napravami itd., prinaša prednosti tudi iz ostalih vidikov na primer optimizacijo delovanja omrežij, kar vodi k učinkovitejši porabi energije in zmanjšanju stroškov.

Pametne naprave in sistemi lahko zbirajo podatke o porabi energije, uporabniških vzorcih in okoljskih pogojih ter na podlagi teh podatkov sprejemajo odločitve, ki izboljšujejo učinkovitost delovanja celotnega sistema. Na primer, pametni termostati lahko prilagajajo temperaturo glede na prisotnost oseb v prostorih, pametne razsvetljave lahko avtomatsko prilagajajo svetilnost glede na naravno svetlobo, pametne vtičnice lahko izklopijo naprave, ko niso v uporabi, s čimer se zmanjšajo stroški energije in vpliv na okolje.

Cilj tega projekta je razviti algoritem, ki na osnovi podatkov o moči porabnikov določi časovno funkcijo prisotnosti dogodka. Kot primer dogodka smo si izbrali: prisotnost osebe doma. Na začetku bomo analizirali vzorce porabe energije različnih naprav, v smislu optimizacije pa bomo uporabili uporabili medote nenadzorovanega učenja, za identifikacijo vzorcev. Končni cilj je rezultate predstaviti kot časovno funkcijo prisotnosti izbranega dogodka. Te rezultati lahko omogočijo optimizacijo delovanja naprav in s tem boljše prilagajanje pametnih sistemov trenutnim razmeram ter potrebam uporabnikov.

2 Pristop k reševanju problema in ocena uspešnosti

Problem, ki ga obravnavamo, je določitev prisotnosti oseb v pametnem domu na podlagi podatkov o porabi energije različnih naprav. Formalno, naj bo X množica časovnih žigov, D množica naprav v domu, $Pd(t)$ pa poraba energije naprave $d \in D$ v času $t \in X$.

Cilj je določiti funkcijo $F(t)$, ki napoveduje prisotnost oseb v domu, kjer $F(t)=1$ pomeni, da je oseba prisotna, in $F(t)=0$, da ni prisotna.

Uporabili bomo metode nenadzorovanega učenja, kot je hierarhično grozdenje, za analizo vzorcev v podatkih $Pd(t)$ in s tem optimizacijo funkcije $F(t)$.

Problem lahko zapišemo kot:

Najdi $F: X \rightarrow \{0,1\}$, ki minimizira napako napovedi prisotnosti oseb na podlagi podatkov $Pd(t)$.

2.1 Metode

Reševanja problema določanja prisotnosti oseb v pametnem domu smo se lotili s pomočjo nenadzorovanega učenja. Uporabili smo metodo aglomerativnega grozdenja (angl. Agglomerative Clustering) [1], ki združuje podatkovne točke v grozde (angl. cluster) postopoma. Začne se tako, da vsako podatkovno točko obravnava kot svoj grozd, nato pa postopoma združuje najbližje grozde, dokler ne ostane samo en velik grozd ali dokler ne dosežemo želenega števila grozdov.

To združevanje poteka na različne načine, v sklopu projekta smo uporabili Wardovo metodo, ki združuje podatkovne točke na način, ki minimizira vsoto kvadratov razlik znotraj grozdov, kar zagotavlja kompaktne in enakomerno velike grozde.

Običajno je smiselno število grozdov nekje med 2 in 10. Za namen določanja števila grozdov smo si pomagali z dendrogramom – gre za drevesni prikaz ponazarja razporeditve grozdov, ki so nastali z analizo. Na podlagi dendrograma smo določili število ustreznih grozdov v katere razdelimo naše podatke.

Seveda smo si morali pred metodo grozdenja podatke ustrezno izbrati in pripraviti. Ker želimo določiti prisotnost oseb v pametnem domu, smo se osredotočili na električne porabnike, ki so neposredno odvisni od prisotnosti uporabnika (npr. mikrovalovna pečica, garažna vrata, poraba v dnevni sobi).

Psevdokoda za postopek določanje časovne funkcije prisotnosti dogodka je prikazana spodaj:

1. Iz podatkov o porabi energije naprav izberemo relevantne porabnike
2. Standardiziramo podatke - Binariziramo podatke glede na določene prage
4. Uporabimo Wardovo metodo za hierarhično grozdenje
5. Ustvarimo dendrogram za vizualizacijo grozdov
6. Določimo število grozdov na podlagi dendrograma
7. Opravimo grozdenje in vizualiziramo rezultate

2.2 Merjenje uspešnosti rešitve

Uspešnost rešitve merimo z natančnostjo identificiranja prisotnosti oseb v domu. Glavni indikator uspešnosti je pravilnost klasifikacije, ki bi jo lahko merili s pomočjo kriterijske funkcije, kot je stopnja točnosti (angl. accuracy), ki primerja napovedane prisotnosti oseb z dejanskimi podatki.

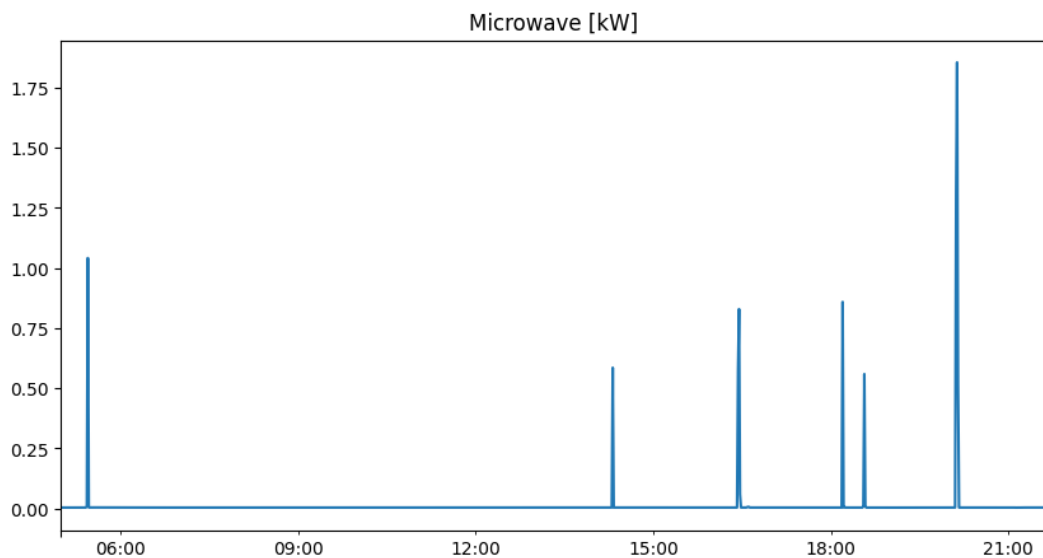
V sklopu projekta bomo uspešnost algoritma ovrednotili z vizualizacijo časovne funkcije prisotnosti dogodka in vizualno primerjavo z dejanskimi vzorci porabe iz katerih sklepamo prisotnosti.

3 Eksperimentalni rezultati

3.1 Testni podatki:

Vhodni podatki za naš algoritem je tabela HomeC.csv, ki vsebuje odčitke porabe hišnih naprav v kW iz pametnega števca v časovnem razponu ene minute, poleg tega pa tudi vremenske razmere. Tabela vsebuje za eno leto podatkov. Za našo izbrano situacijo se bomo osredotočili na porabnike: Microwave, Garage door in Living room.


Primer podatkov za Microwave za prvih 1000 vzorcev (približno 16ur) je prikazan spodaj:



Slika 1: Poraba Microwave v kW za prvih 1000 vzorcev


Iz podatkov najprej odstranimo šum na merilni napravi. To storimo tako, da vizualno in s pomočjo histograma določimo prag in podatke bineriziramo. Tako smo dobili »on/off« vrednosti za posamezno napravo.

Primer za Microwave je prikazan spodaj:



Slika 2: ON/OFF vrednosti za Microwave


Binerizirane podatke za naprave microwave, Garage door in Living room smo združili in uporabili v wardovi metodi hierarhičnega grozdenja. Rezultate lahko prikažemo kot dendrogram.



Slika 3: Dendrogram

Na podlagi dendrograma določimo število grozdov. Smiselno število grozdov bi lahko bilo 4 (kjer je distance približno 3) ali 2 (distance približno 10). V našem primeru, ko želimo detekcijo prisotnosti situacije, smo izbrali 2 grozda.


Sedaj lahko izvedemo aglomerativno grozdenje in rezultate predstavimo kot časovno funkcijo prisotnosti osebe doma v odvisnosti od časa:




Slika 4: Rezultat - Prisotnost osebe v domu

3.2 Ovrednotenje rezultata


Če pogledamo rezultate vidimo, da naš algoritem za prvih 1000 vzorcev (prvih 16 ur) kaže na prisotnost oseb v domu med 14:15 in 19:15 uro. Če rezultate primerjamo z realnimi in bineriziranimi vrednostmi v tem obdobju, vidimo da je algoritem precej uspešno in pravilno določil prisotnost osebe na podlagi izbranih podatkov.



Slika 5: Izmerjene vrednosti porabnikov v kW skozi čas



Slika 6: Binarne vrednosti porabnikov



Slika 7: Prisotnost osebe in binarne vrednosti porabnikov skozi čas

Zaključimo lahko, da naš algoritem na izbranem primeru uspešno detektira prisotnost oseb v domu.

4 Izzivi

Skozi projekt se je pojavilo kar nekaj izzivov. Eden glavnih je bil velikost podatkov, saj smo naleteli na težavo pri uporabi funkcij za hierarhično grozdenje zaradi velike količine podatkov. Metoda Ward zahteva veliko računsko moč in pomnilnik, saj minimizira vsoto kvadratov razlik znotraj grozdov. Ko smo poskusili obdelati celoten nabor podatkov, smo naleteli na napako *MemoryError*, saj sistem ni mogel dodeliti dovolj pomnilnika za izvedbo izračunov. Zato smo se omejili na 1000 vzorcev, da smo lahko metodo uspešno uporabili.

5 Zaključek in možne nadgradnje

Skozi projekt smo uspešno razvili algoritem za določanje časovne funkcije prisotnosti oseb v pametnem domu na podlagi podatkov o porabi energije različnih naprav. S pomočjo aglomerativnega grozdenja - metode za hierarhično grozdenje smo analizirali vzorce električne porabe naprav in identificirali prisotnost oseb v domu. Razviti algoritem omogoča učinkovitejše prilagajanje pametnih sistemov trenutnim razmeram in potrebam uporabnikov, kar lahko prispeva k večji energetske učinkovitosti in udobju v pametnih domovih.

Osnovno verzijo projekta bi lahko nadgradili z integracijo večjega števila naprav – predvsem tistih, ki so neposredno odvisne od prisotnosti uporabnika (npr. televizor, računalnik, radio, fen). Lahko bi vključili kontekst v smislu razmer v okolici (temperatura, vlaga...). V sklopu nenadzorovanega učenja bi lahko preizkusili še ostale metode strojnega učenja ali celo nadgradili naš model, mu dodali oznake (angl. labels) in uporabili nadzorovano strojno učenje.

Skratka, tematika situacijskega zavedanja v pametnem domu je izjemno aktualna. Naš algoritem prinaša številne prednosti za uporabnike, saj izboljšuje uporabniško izkušnjo in energetsko učinkovitost pametnega doma. S tem pa ne koristi le posameznikom, temveč tudi celotnemu omrežju.

6 Literatura

- [1] „Implementing Agglomerative Clustering using Sklearn“, GeeksforGeeks. Pridobljeno: 19. maj 2024. [Na spletu]. Dostopno na: <https://www.geeksforgeeks.org/implementing-agglomerative-clustering-using-sklearn/>
- [2] *Flat and Hierarchical Clustering / The Dendrogram Explained*, (15. januar 2019). Pridobljeno: 19. maj 2024. [Na spletu Video]. Dostopno na: <https://www.youtube.com/watch?v=ijUMKMC4f9I>
- [3] „Dendrogram“, *Wikipedia*. 12. januar 2024. Pridobljeno: 19. maj 2024. [Na spletu]. Dostopno na: <https://en.wikipedia.org/w/index.php?title=Dendrogram&oldid=1195077958>
- [4] „sklearn.cluster.AgglomerativeClustering“, scikit-learn. Pridobljeno: 19. maj 2024. [Na spletu]. Dostopno na: <https://scikit-learn/stable/modules/generated/sklearn.cluster.AgglomerativeClustering.html>
- [5] „smart_home_data_processing___weather_vs_energy“. Pridobljeno: 19. maj 2024. [Na spletu]. Dostopno na: <https://kaggle.com/code/malekzadeh/smart-home-data-processing-weather-vs-energy>
- [6] „ChatGPT“. Pridobljeno: 19. maj 2024. [Na spletu]. Dostopno na: <https://chatgpt.com>
Pri pisanju poročila je bil uporabljen ChatGPT verzija 4o.